RETO Sandbox de IA en GCP con Terraform

Resumen

El proyecto construye en GCP un datacenter virtual diseñado como sandbox de IA: un entorno aislado donde los equipos experimentan con modelos generativos, entrenan y ajustan modelos propios y prototipan aplicaciones, sin riesgo para producción ni para los datos sensibles. El entregable final es un repositorio de Terraform que despliega toda la plataforma y crea sandboxes por equipo bajo demanda.

La base es la misma landing zone de un datacenter empresarial (organización, red, seguridad, observabilidad). Sobre ella se agregan Vertex AI, cómputo con GPU y TPU, almacenamiento de datasets, búsqueda vectorial, MLOps y controles de uso responsable y de costo. La entrega es el jueves 3 de diciembre de 2026, tras 5 sprints de dos semanas.

Objetivos, casos de uso y alcance

El sandbox debe permitir que un equipo pase de una idea a un prototipo de IA funcionando en días, con costo acotado y sin tocar producción.

Objetivos medibles

1. Crear un sandbox nuevo para un equipo en menos de 30 minutos, con un PR o un formulario de autoservicio.
2. Desplegar la plataforma completa desde cero con un solo pipeline, sin pasos manuales fuera del bootstrap.
3. Ningún sandbox supera su presupuesto mensual: alertas al 50, 80 y 100 % y apagado automático de GPU al 100 %.
4. Cero datos productivos sin anonimizar dentro del sandbox, verificado con Sensitive Data Protection.

Casos de uso que el sandbox debe soportar

Caso de uso	Ejemplo	Servicios principales
IA generativa con modelos administrados	Asistente interno que responde con documentos de la empresa (RAG)	Gemini en Vertex AI, Vector Search, Cloud Storage
Modelos abiertos	Probar y comparar Llama, Gemma o Mistral	Model Garden, endpoints de Vertex AI, GKE con GPU
Ajuste fino (fine-tuning)	Adaptar un modelo al lenguaje del negocio	Vertex AI Training, GPU A100/H100 o TPU
ML clásico	Pronóstico de demanda, clasificación	BigQuery ML, Vertex AI Training, Workbench

Caso de uso	Ejemplo	Servicios principales
Agentes	Agente que consulta APIs internas	Vertex AI Agent Builder, Cloud Run
Evaluación de modelos	Medir calidad y seguridad antes de pasar a producción	Vertex AI Evaluation, Experiments

Dentro del alcance

- Landing zone base: organización, carpetas, políticas, red hub-and-spoke, HA VPN, seguridad y observabilidad.
- Plataforma de IA compartida: Vertex AI, Model Garden, Vector Search, Artifact Registry, Feature Store y Pipelines.
- Cómputo acelerado: GKE con node pools de GPU, Workbench con GPU y cuotas de TPU.
- Datos: lago de datasets en Cloud Storage, BigQuery y canal de anonimización.
- Fábrica de sandboxes por equipo con presupuesto, caducidad y limpieza automática.
- Controles de IA responsable: filtrado de prompts, registro de peticiones y lista de modelos permitidos.
- Repositorio Terraform, pipeline CI/CD y documentación.

Fuera del alcance

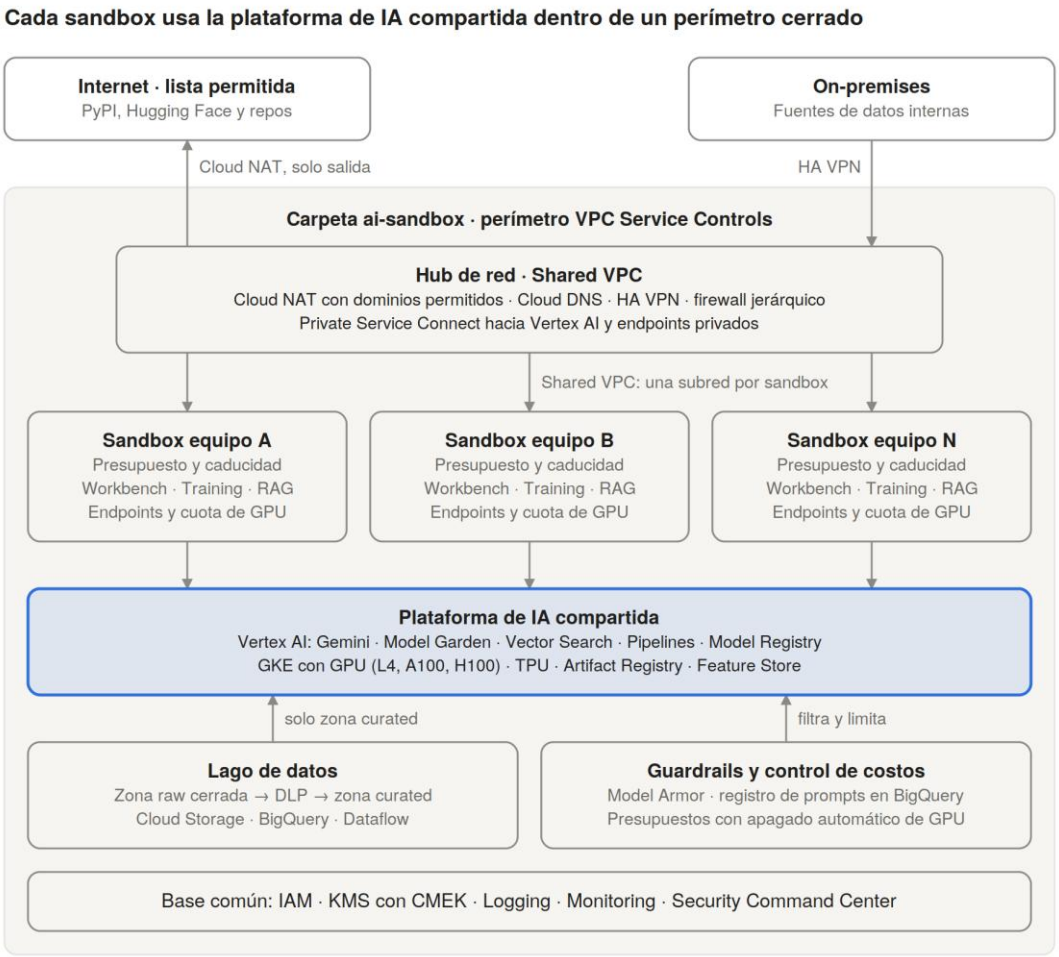
- Desarrollo de los casos de uso o de modelos de negocio.
- Paso a producción de modelos (se especifica la interfaz de salida, no la plataforma productiva).
- Contratación de capacidad reservada de GPU o TPU.

Supuestos y restricciones

- Región principal us-central1, por tener la mayor oferta de GPU, TPU y modelos Gemini; us-east4 como región alterna para capacidad de GPU.
- La disponibilidad de GPU H100 y TPU depende de cuotas aprobadas por Google; se solicitan en la semana 1.
- El sandbox no requiere alta disponibilidad multirregión: se respaldan datasets y modelos, no el cómputo.
- Terraform ≥ 1.9 y proveedores google y google-beta 6.x.

Arquitectura de referencia

Los sandboxes son proyectos por equipo dentro de una carpeta aislada; todos consumen una plataforma de IA compartida y solo ven datos anonimizados.



Arquitectura de referencia · sandbox de IA en GCP

La salida a Internet está limitada a repositorios aprobados y la entrada desde on-premises llega solo por HA VPN; todo queda dentro del perímetro VPC Service Controls.

Jerarquía de recursos

- **Carpeta bootstrap**: proyecto semilla con el estado de Terraform y las cuentas del pipeline.
- **Carpeta common**: proyectos net-hub, logging y security.
- **Carpeta ai-sandbox**: proyectos ai-platform (servicios compartidos), ai-data (lago de datos) y un proyecto aisbx-<equipo> por cada sandbox.

Componentes del sandbox

El sandbox tiene dos capas: la base del datacenter, compartida y estable, y la plataforma de IA, donde los equipos experimentan.

Capa base del datacenter

Dominio	Servicios GCP	Configuración mínima exigida	Módulo Terraform
Organización y gobierno	Resource Manager, Org Policies, Billing	Carpeta ai-sandbox aislada de producción; regiones permitidas; sin llaves de cuentas de servicio	org, folders
Identidad	Cloud Identity, IAM, Workload Identity Federation	Grupos por equipo y rol (científico de datos, ingeniero ML, revisor)	iam
Red	Shared VPC hub-and-spoke, Cloud NAT, Cloud DNS	Subredes privadas; Private Google Access; Private Service Connect hacia Vertex AI	network-hub, network-spoke
Conectividad híbrida	HA VPN	Acceso a fuentes de datos on-premises por IP privada	hybrid-connectivity
Seguridad	Firewall jerárquico, Cloud KMS, Secret Manager, VPC Service Controls	Perímetro VPC-SC alrededor de los proyectos de IA y datos; CMEK en todo	firewall, kms, vpc-sc
Observabilidad	Cloud Logging, Monitoring, Security Command Center	Logs de auditoría centralizados; tableros de uso de GPU y tokens	observability

Capa de plataforma de IA

Dominio	Servicios GCP	Configuración mínima exigida	Módulo Terraform
Entornos de trabajo	Vertex AI Workbench (instancias)	Imágenes con frameworks de ML; sin IP pública; apagado automático tras 60 min de inactividad	workbench
Modelos administrados	Gemini en Vertex AI, Model Garden	Lista de modelos permitidos por política de organización; cuotas por proyecto	vertex-models
Cómputo acelerado	GKE con node pools de GPU (L4, A100, H100), TPU, Cloud Run con GPU	Node pools que escalan a cero; VM Spot por defecto en entrenamiento	gke-gpu, tpu
Entrenamiento y ajuste	Vertex AI Training, Experiments, TensorBoard	Trabajos con contenedores de Artifact Registry; métricas registradas	vertex-training
Servicio de modelos	Endpoints de Vertex AI, vLLM en GKE	Endpoints privados por Private Service Connect; escalado a cero fuera de	vertex-endpoints

Dominio	Servicios GCP	Configuración mínima exigida	Módulo Terraform
		horario	
RAG y búsqueda	Vertex AI Vector Search, AlloyDB o Cloud SQL con pgvector, Vertex AI Search	Índices por equipo; embeddings con modelos de Vertex AI	vector-search
Agentes	Vertex AI Agent Builder, Cloud Run	Herramientas limitadas a APIs internas aprobadas	agents
Datos	Cloud Storage, BigQuery, Dataflow, Sensitive Data Protection	Zona raw cerrada y zona curated anonimizada, la única visible a los sandboxes	data-lake, dlp-pipeline
MLOps	Vertex AI Pipelines, Model Registry, Feature Store, Artifact Registry	Versionado de modelos y datasets; linaje registrado	mlops
Guardrails	Model Armor, filtros de seguridad de Vertex AI, registro de peticiones y respuestas en BigQuery	Bloqueo de inyección de prompts y fuga de datos sensibles	ai-guardrails
Control de costos	Budgets, Pub/Sub, Cloud Run functions	Presupuesto por sandbox; apagado de GPU y endpoints al llegar al 100 %	cost-guard
Fábrica de sandboxes	Project Factory + etiquetas de caducidad	Un proyecto por equipo con cuotas, presupuesto y fecha de expiración; borrado automático al vencer	sandbox-factory

Seguridad, gobierno y uso responsable de IA

El sandbox es libre para experimentar, pero nada sale de él sin control: ni datos sensibles, ni modelos no aprobados, ni gasto sin límite.

Aislamiento

- Carpeta ai-sandbox separada de producción; los sandboxes no tienen rutas de red hacia proyectos productivos.
- Perímetro VPC Service Controls que impide copiar datos de BigQuery, Cloud Storage o Vertex AI fuera de los proyectos autorizados.
- Sin IP públicas; la salida a Internet pasa por Cloud NAT con una lista de dominios permitidos (repositorios de paquetes y de modelos).

Datos

- Los sandboxes solo leen la zona curated del lago de datos.

- Todo dataset que entra a curated pasa por Sensitive Data Protection para detectar y enmascarar datos personales.
- Clasificación de datasets con etiquetas de sensibilidad; los de nivel alto requieren aprobación del dueño de datos.

Modelos y uso responsable

- Política de organización con la lista de modelos de Model Garden permitidos; incorporar uno nuevo requiere revisión de licencia y de seguridad.
- Model Armor y los filtros de seguridad de Vertex AI analizan prompts y respuestas: inyección de prompts, contenido dañino y fuga de datos sensibles.
- Registro de peticiones y respuestas de los endpoints en BigQuery, con retención de 90 días, para auditoría y evaluación.
- Ningún modelo pasa a producción desde el sandbox sin una ficha de modelo, resultados de evaluación y aprobación del comité de IA.

Roles

Rol	Puede	No puede
Científico de datos	Usar Workbench, entrenar, desplegar endpoints en su sandbox	Leer la zona raw; crear redes o cambiar IAM
Ingeniero ML	Lo anterior + administrar GKE con GPU y pipelines del equipo	Exceder cuotas o presupuesto asignado
Líder de equipo	Solicitar sandboxes, ampliar presupuesto dentro de su límite	Aprobar sus propios cambios en producción
Equipo de plataforma	Administrar la base y los módulos de Terraform	Acceder a los datos de los equipos

Requisitos no funcionales y control de costos

En un sandbox de IA el riesgo principal no es la caída del servicio sino el gasto: una GPU olvidada encendida puede costar miles de dólares al mes.

Categoría	Requisito	Métrica objetivo	Cómo se verifica
Disponibilidad	Plataforma compartida (Vertex AI, red, datos)	99.5 % mensual en horario laboral	SLO en Cloud Monitoring
Recuperación	Datasets, modelos y código respaldados	RPO ≤ 24 h; cómputo se recrea con Terraform	Prueba de restauración
Aprovisionamiento	Sandbox nuevo listo	< 30 min	Medición en pipeline
Rendimiento	Arranque de node pool de GPU desde cero	< 10 min	Prueba de escalado

Categoría	Requisito	Métrica objetivo	Cómo se verifica
Seguridad	Cifrado con llaves del cliente	100 % de buckets, discos, BigQuery y Vertex AI con CMEK	Política de organización
Seguridad	Exfiltración de datos	0 copias fuera del perímetro	Logs de VPC Service Controls
Costos	Gasto por sandbox	≤ presupuesto asignado	Budgets con acciones automáticas
Costos	GPU ociosas	0 GPU encendidas sin uso > 60 min	Apagado automático y alerta
Operación	Sandboxes vencidos	Borrado a los 7 días de la fecha de expiración, previo aviso	Job programado de limpieza

Medidas de control de costos

- VM Spot por defecto para entrenamiento y Workbench de pruebas (60–91 % más baratas que bajo demanda).
- Node pools de GPU y endpoints que escalan a cero fuera de horario.
- Cuotas de GPU por sandbox (p. ej. máximo 4 L4 y 1 A100 sin aprobación adicional); H100 y TPU solo con solicitud.
- Presupuesto por sandbox con acción automática: al 100 % se detienen GPU, Workbench y endpoints.
- Tablero de costos por equipo, modelo y tipo de acelerador, con datos de facturación exportados a BigQuery.

Especificación del entregable Terraform

El repositorio separa la base compartida, desplegada una vez, de la fábrica de sandboxes, que crea un proyecto por equipo a partir de un archivo de configuración.

Estructura del repositorio

```
gcp-ai-sandbox/
├── modules/
│   ├── project-factory/  network-hub/  network-spoke/  firewall/
│   ├── kms/  vpc-sc/  observability/  hybrid-connectivity/
│   ├── workbench/          # Instancias con apagado por inactividad
│   ├── gke-gpu/            # Clúster privado con node pools L4/A100/H100
│   ├── tpu/
│   ├── vertex-models/      # Model Garden, Gemini, política de modelos permitidos
│   ├── vertex-training/
│   ├── vertex-endpoints/
│   ├── vector-search/
```

```
│   ├── agents/
│   ├── data-lake/  dlp-pipeline/
│   ├── mlops/              # Pipelines, Model Registry, Feature Store
│   ├── ai-guardrails/      # Model Armor y registro de peticiones
│   └── cost-guard/         # Presupuestos y apagado automático
├── stages/
│   ├── 0-bootstrap/        # Proyecto semilla, estado remoto, SA del pipeline
│   ├── 1-org/              # Carpetas, org policies, logging, SCC
│   ├── 2-security/         # KMS, Secret Manager, VPC-SC
│   ├── 3-networks/         # Hub, spokes, DNS, VPN, PSC
│   ├── 4-ai-platform/      # Datos, Vertex AI compartido, GKE GPU, guardrails
│   └── 5-sandboxes/        # Un proyecto por equipo
│       └── teams/*.yaml
├── policies/  tests/  docs/
└── .github/workflows/      # o cloudbuild/
```

Alta de un sandbox: el líder de equipo agrega un archivo YAML y abre un PR; el pipeline crea el proyecto con su red, cuotas, presupuesto y permisos.

```yaml
# stages/5-sandboxes/teams/analitica.yaml
team: analitica
owner_group: gcp-ai-analitica@empresa.com
expires: 2027-03-31
monthly_budget_usd: 3000
gpu_quota:
  nvidia-l4: 4
  nvidia-a100: 1
allowed_services: [workbench, vertex-training, vertex-endpoints, vector-search]
data_access: [curated/ventas, curated/clientes_anon]
```

Convenciones obligatorias

- Estado remoto en GCS con un prefijo por etapa y por sandbox; versionado y CMEK.
- Versiones fijadas de Terraform y proveedores, con .terraform.lock.hcl versionado.
- Nombres <empresa>-aisbx-<equipo>-<recurso>; etiquetas obligatorias team, owner, cost_center, expires, managed_by.
- Recursos de Vertex AI que aún solo existen en google-beta se declaran con ese proveedor de forma explícita.
- Sin secretos en código; autenticación del pipeline por Workload Identity Federation.
- Se permite reutilizar módulos oficiales (Cloud Foundation Fabric, terraform-google-modules) con versión fijada.

Variables principales de la plataforma

Variable	Tipo	Ejemplo	Descripción
org_id	string	123456789012	ID de la organización
region	string	us-central1	Región principal de

Variable	Tipo	Ejemplo	Descripción
			IA
allowed_models	list(string)	["gemini", "gemma", "llama"]	Familias de modelos permitidas
gpu_node_pools	map(object)	{ l4 = { machine_type = "g2-standard-8", max = 8, spot = true } }	Node pools de GPU en GKE
workbench_idle_minutes	number	60	Minutos de inactividad antes del apagado
prompt_log_retention_days	number	90	Retención del registro de peticiones
default_sandbox_budget_usd	number	2000	Presupuesto mensual por defecto

CI/CD y gobierno de IaC

Los cambios a la base requieren revisión del equipo de plataforma; las altas de sandboxes se aprueban solo con la firma del líder de equipo, si cumplen las políticas.

Flujo del pipeline (GitHub Actions o Cloud Build)

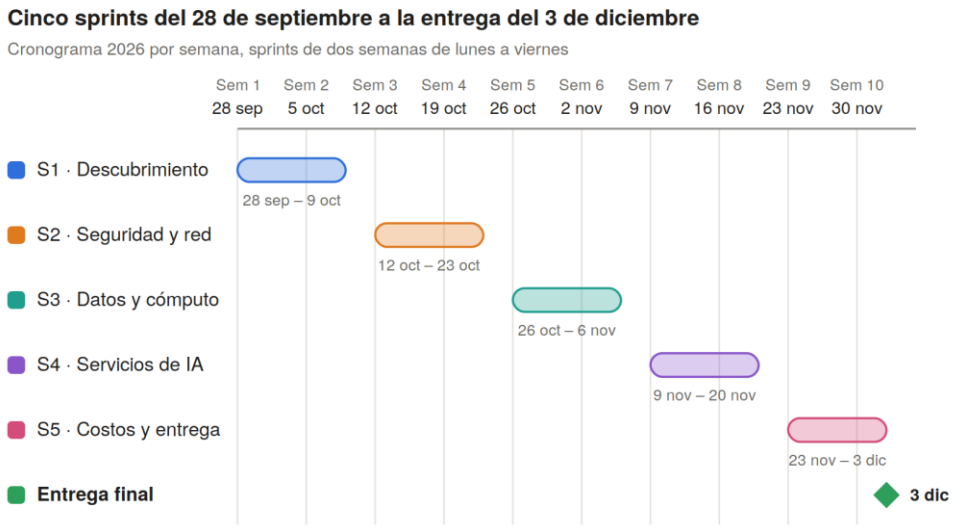
1. **Pull request**: terraform fmt, validate, tflint y escaneo de seguridad con checkov.
2. **Políticas como código** sobre el plan: se rechazan sandboxes sin fecha de expiración o sin presupuesto, cuotas de GPU por encima del límite, modelos fuera de la lista permitida y acceso a la zona raw.
3. **Plan con estimación de costo** (Infracost) publicado en el PR; si el costo fijo estimado supera el presupuesto del sandbox, el PR se bloquea.
4. **Aprobación**: base y plataforma con dos revisores de plataforma; sandboxes con el líder del equipo.
5. **Apply** automático tras el merge.
6. **Tareas programadas**: detección de drift diaria, aviso de sandboxes por vencer a 14 y 3 días, y borrado de los vencidos.

Gobierno

- CODEOWNERS: plataforma para modules/ y stages/0-4; cada equipo para su archivo en teams/.
- Una cuenta de servicio por etapa y otra por sandbox, con permisos mínimos.
- Versionado semántico de módulos y registro de decisiones (ADR) en docs/adr/.

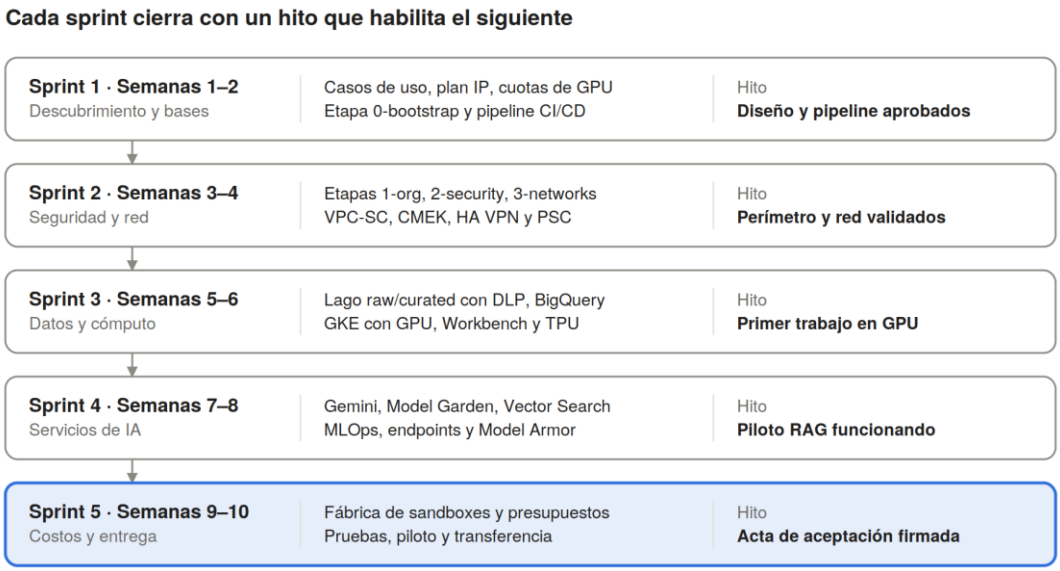
Plan de trabajo

El proyecto dura 10 semanas en 5 sprints de dos semanas: arranca el lunes 28 de septiembre y se entrega el jueves 3 de diciembre de 2026.



Cronograma · 28 sep a 3 dic 2026

El sprint 5 tiene 9 días hábiles porque cierra con la entrega del jueves; el lunes 16 de noviembre (Día de la Revolución) cae en el sprint 4.



Hoja de ruta · 5 sprints con sus hitos

Ningún sprint empieza sin cerrar el hito del anterior. La cuota de GPU se pide en la semana 1 porque el sprint 3 depende de ella.

Roles y responsabilidades

Rol	Responsabilidad
Líder de proyecto	Plan, riesgos, comunicación con el cliente
Arquitecto cloud	Diseño de la base y ADR
Arquitecto de ML	Diseño de la plataforma de IA, MLOps y guardrails
Ingeniero de IaC (2)	Módulos, etapas, fábrica de sandboxes y pruebas
Ingeniero de seguridad	VPC-SC, DLP, IAM, políticas como código
Equipo piloto del cliente	Caso de uso de prueba en el sprint 4 y 5

Criterios de aceptación y pruebas

El acta se firma cuando un equipo piloto completa un caso de uso de punta a punta dentro de su sandbox y todos los controles se comprueban.

Criterios de aceptación

- ☐ La plataforma se despliega desde cero (etapas 0 a 4) sin errores; un segundo plan reporta cero cambios.
- ☐ Un sandbox nuevo se crea desde un YAML en menos de 30 minutos y se elimina limpio al vencer.
- ☐ El equipo piloto construye un prototipo RAG con Gemini y Vector Search sobre datos de la zona curated.
- ☐ Un trabajo de ajuste fino corre en GPU Spot y el modelo queda registrado en Model Registry.
- ☐ Un modelo abierto de Model Garden se sirve en un endpoint privado y responde por Private Service Connect.
- ☐ Un modelo fuera de la lista permitida es rechazado por la política.
- ☐ Model Armor bloquea un intento de inyección de prompts y uno de fuga de datos personales de prueba.
- ☐ Copiar datos fuera del perímetro VPC-SC falla y queda registrado.
- ☐ Al agotar el presupuesto de prueba, las GPU y endpoints del sandbox se detienen solos.
- ☐ Una instancia de Workbench inactiva se apaga a los 60 minutos.

Estrategia de pruebas

Nivel	Herramienta	Qué valida	Cuándo
Estático	fmt, validate, tflint, checkov	Sintaxis, buenas prácticas, seguridad	Cada PR

Nivel	Herramienta	Qué valida	Cuándo
Políticas	OPA/Conftest	Expiración, presupuesto, cuotas, modelos permitidos	Cada PR
Unitario	terraform test con mock_provider	Lógica de módulos y de la fábrica de sandboxes	Cada PR
Integración	Terratest en proyecto efímero	Recursos reales de Vertex AI, GKE GPU y guardrails	Nocturno
Extremo a extremo	Equipo piloto con un caso de uso real	Flujo completo y controles	Sprint 5

Documentación entregable: README de despliegue, guía para equipos (¿cómo pido un sandbox?, ¿cómo uso GPU sin gastar de más?), runbooks de operación y ADR.

Riesgos y estimación de costos

El riesgo más probable es no conseguir cuota de GPU a tiempo; el de mayor impacto, que datos sensibles entren al sandbox.

Riesgo	Probabilidad	Impacto	Mitigación
Cuota de GPU H100 o TPU no aprobada a tiempo	Alta	Alto	Solicitud en la semana 1; plan con L4 y A100; región alterna us-east4
Datos personales sin anonimizar en el sandbox	Media	Muy alto	Solo zona curated, Sensitive Data Protection, VPC-SC
Gasto descontrolado de GPU o tokens	Alta	Alto	Presupuestos con apagado automático, Spot, escalado a cero, cuotas
Recursos de Vertex AI sin soporte completo en Terraform	Media	Medio	Proveedor google-beta; módulos aislados para actualizar sin tocar la base
Modelos abiertos con licencias incompatibles	Media	Medio	Lista de modelos permitidos con revisión legal
Sandboxes abandonados	Alta	Medio	Fecha de expiración obligatoria y borrado automático
Prototipos que pasan a producción sin control	Media	Alto	Sin rutas hacia producción; ficha de modelo y comité de IA

Estimación de costo mensual (aproximada, en USD, precios de lista bajo demanda en us-central1; validar con la Calculadora de precios de Google Cloud)

Componente	Supuesto de dimensionamiento
Base compartida (red, VPN, NAT, logging, KMS)	Igual que un datacenter pequeño

Componente	Supuesto de dimensionamiento
Plataforma de IA compartida	GKE (tarifa de clúster), Vector Search con 1 nodo, Artifact Registry, BigQuery
Sandbox típico	2 GPU L4 8 h/día en días hábiles, Workbench, tokens de Gemini moderados
Ajuste fino puntual	1 A100 durante 40 h (Spot reduce 60–90 %)
Uso intensivo	8 GPU H100 durante 24 h